

Архитектура внедрения LLM в закрытом контуре КИИ

Руководство для CISO, ИТ-директоров и архитекторов решений

Документ

Версия 1.0 · 2026

Аудитория

CISO, ИТ-директора, руководители цифровой трансформации, главные архитекторы, специалисты по защите информации

Объём

Эталонная архитектура, регуляторный контекст, сценарии развёртывания, чек-лист готовности к пилоту

О документе

Документ предназначен для архитекторов и владельцев продуктов в крупных компаниях и государственных организациях, которые рассматривают внедрение LLM и других нейросетевых решений в закрытом контуре.

В нём собраны нормативный контекст развёртывания ИИ в КИИ и госсекторе, типовая архитектура on-premise решения, разбор ИБ-обязки вокруг модели, требования к отечественному стеку, сценарии развёртывания и методология пилотного проекта. В конце — чек-лист готовности к пилоту и реестр рисков.

Документ не заменяет проектную документацию для конкретного объекта. Цифры, версии ПО и SKU оборудования здесь даны как ориентир: точные значения определяются на обследовании.

Если у вас уже есть утверждённая архитектура и нужен только чек-лист готовности к пилоту, переходите к разделу 7.

1. Регуляторный контекст

Внедрение генеративного ИИ в крупных российских организациях и в госсекторе не существует в нормативном вакууме. Требования к архитектуре и развёртыванию задаёт не маркетинг, а нормативная база по защите информации, персональным данным и критической инфраструктуре.

1.1 Ключевые нормативные акты

Чаще всего архитектурные решения по on-premise ИИ определяются пятью группами документов. Перечень условный: точный набор требований всегда зависит от конкретного объекта, его категории и отрасли.

187-ФЗ «О безопасности критической информационной инфраструктуры» вводит само понятие КИИ, требует категорирования объектов (1–3 категория), регистрации значимых объектов и принятия мер защиты. Из него вытекают многие архитектурные ограничения, включая правила обмена данными с внешними системами.

152-ФЗ «О персональных данных» регулирует любую обработку ПДн, в том числе при использовании ИИ. Подключение каждого нового внешнего сервиса требует переоценки политики обработки. Передача ПДн в публичные облачные ИИ-сервисы — отдельная процедура со своими рисками.

Приказы ФСТЭК 17, 21 и 235 определяют меры защиты информации в государственных информационных системах, на объектах КИИ и в системах персональных данных. Архитектура ИИ-системы должна быть совместима с этими мерами либо реализовывать их собственными средствами.

Постановления Правительства 1236, 145 и 325 регулируют закупку отечественного ПО для государственных и муниципальных нужд. Реестр отечественного ПО Минцифры — формальное требование для большинства закупок в госсекторе.

Регулирование ИИ в горизонте 2027 года ещё формируется. Оно затронет в первую очередь оборот моделей: реестр доверенных систем, требования к объяснимости, обязательное журналирование решений. Архитектуру стоит закладывать с учётом этого горизонта, чтобы потом не переделывать.

Перечисленным список не закрывается. Для отдельных отраслей он шире: в финансовом секторе добавляются требования ЦБ РФ, в телекоме — регуляторика ТСПУ, в промышленности — требования Ростехнадзора. При работе под конкретную отрасль набор актов расширяется отдельно — об этом стоит договариваться с заказчиком в первые недели обследования.

1.2 Что из этого следует для архитектуры

Архитектурно из перечисленного вытекает четыре ограничения. Первое и самое жёсткое — локализация данных: передача за пределы инфраструктуры заказчика всегда требует обоснования, а для отдельных категорий — отдельных согласований с регулятором.

Второе ограничение сетевое. Значимые объекты КИИ 1–2 категории отделены от публичных сетей, и использование внешнего ИИ-сервиса противоречит этому

требованию по умолчанию. Шлюзовая обвязка, через которую теоретически можно подключить облако, на практике нивелирует все его преимущества — проще развернуть модель внутри.

Третье касается аудита. Регулятор требует полной фиксации действий в системе. У публичного провайдера полнота журналов ограничена API и условиями SLA, и этого может быть недостаточно для собственной службы ИБ заказчика.

И четвёртое — формальное требование реестра отечественного ПО Минцифры для закупок в госсекторе. На бумаге это «формальный фильтр», но фактически он переписывает архитектуру на трёх уровнях: ОС (Astra Linux или РЕД ОС вместо условного Debian), СУБД (Postgres Pro вместо ванильного PostgreSQL), платформа виртуализации (РусБИТех Брест или ECP Veil вместо VMware или Hyper-V).

Дополнительная цена — тесты совместимости и работа с ограниченным набором GPU-драйверов под сертифицированным ядром ОС: NVIDIA-драйверы под Astra или РЕД ОС обновляются с задержкой по сравнению с upstream-каналами.

Отдельно стоит упомянуть аттестацию. На объектах высоких категорий КИИ требование об аттестации распространяется не только на систему в целом, как часто предполагает заказчик в начале проекта, а на каждый вводимый в схему компонент. Это влияет на выбор стека ещё до технического проектирования, поэтому вопрос «что именно подлежит аттестации» лучше задавать на первой встрече, а не на пятой неделе пилота.

На полях

Эта подборка — компас, не инструкция. По конкретному объекту нормативные требования всегда уточняются совместно со службой защиты информации заказчика, и набор может оказаться существенно шире.

2. Почему публичный облачный ИИ не подходит для КИИ

Регуляторный контекст — это формальная сторона. Но даже там, где облачное использование ИИ юридически допустимо, оно создаёт операционные риски, с которыми сложно работать в крупной организации.

2.1 Что попадает в промпт

К ИИ-системе в крупной компании рано или поздно подключается всё подряд: документы СЭД, договоры, обращения клиентов, технологическая документация, события ИБ, выгрузки из CRM и ERP. Каждый фрагмент, который уходит в публичный сервис, требует объяснения по защите данных. Это объяснение часто нечем подтвердить: даже если поставщик облака декларирует политики, технических средств для аудита у заказчика нет.

К этому добавляется сетевая изоляция. Значимые объекты КИИ 1–2 категории отделены от публичных сетей, и шлюзовая обвязка для безопасного подключения внешнего сервиса нивелирует преимущества облака.

2.2 Теневой ИИ и долгие согласования

Запретительные политики в отношении публичных ИИ-сервисов работают слабо, когда у сотрудника нет легальной альтернативы. Без on-premise решения организация получает «теневой ИИ»: сотрудник в одиннадцать вечера копирует фрагмент договора или жалобу клиента в публичный чат — не как злоумышленник, а потому что хочет домой. Контролировать это сложнее, чем дать удобный легальный инструмент.

С другой стороны, формальное подключение внешнего SaaS в крупной организации — это отдельный проект на 4–8 месяцев: комитет, владелец риска, оценка поставщика, юридическая экспертиза, согласование с ИБ. Часто за это время быстрее развернуть LLM в собственной стойке.

2.3 Эволюция требований

Регулирование ИИ в РФ активно формируется. Архитектура, привязанная к конкретному облачному поставщику, плохо адаптируется к новым требованиям, будь то реестр доверенных моделей, объяснимость или обязательное журналирование. Контур, в котором компоненты под контролем заказчика, приспособливается легче.

3. Типовая архитектура

В этом разделе разбирается архитектура on-premise LLM-системы, которая встречается в большинстве промышленных внедрений в защищённом контуре. Это не единственно возможная топология, но базовые компоненты в ней одни и те же.

3.1 Слои системы

Архитектура распадается на семь логических слоёв. Каждый слой может быть реализован разными технологиями — ниже типичные варианты, которые встречаются в проектах под госсектор и крупный корпоративный сегмент.

Слой	Назначение	Технологии
Источники данных	Документы, базы знаний, события ИБ, телеметрия оборудования	СЭД (1С:Документооборот, Directum, Тезис, ELMA), ERP (1С, SAP), файловые хранилища, SIEM, SCADA
Коннекторы и индексация	Извлечение, нормализация, дедупликация, очистка от ПДн при необходимости	Apache Tika, собственные экстракторы, ETL-инструменты
Векторная база данных	Хранение эмбеддингов, метаданных, прав доступа	Postgres Pro + pgvector, FAISS, Milvus, Qdrant
LLM-узел	Генерация ответов на запросы пользователя	Открытые модели (LLaMA, Mistral, Saiga, Qwen) или российские (GigaChat lite, YandexGPT в контуре)
RAG-слой	Поиск контекста, ранжирование, формирование промпта	Собственная реализация, LangChain или LlamaIndex (с осторожностью к зависимостям)
ИБ-обвязка	RBAC, журналирование, маскирование, DLP, защита от prompt injection	Собственные модули + интеграция со СЗИ заказчика
Пользовательский интерфейс	Web-интерфейс, API, плагины к СЭД и почтовым клиентам	Web SPA, REST API (OpenAPI), плагины Outlook, 1С, Directum

Из практики выбор модели в LLM-узле в проектах под КИИ и закрытый контур распределяется примерно 80 на 20 в пользу открытых международных моделей (LLaMA, Mistral, Saiga, Qwen): они не требуют внешнего API, разворачиваются без зависимостей от облака и поддаются fine-tuning под специализированную терминологию заказчика. Российские модели в контуре (GigaChat lite, YandexGPT) пока встречаются реже, но в закрытом исполнении дают высокую базовую точность на русском языке в типовых сценариях — туда, где это важнее гибкости настройки, имеет смысл смотреть в их сторону.

На уровне векторного хранилища стандарт — Postgres Pro с расширением pgvector. Этот выбор закрывает большинство пилотов и первых промышленных внедрений: проходит реестровый фильтр и хватает на базовые сценарии. Специализированные

базы (Milvus, Qdrant) добавляются в дополнение к Postgres Pro, когда речь идёт о десятках миллионов векторов или жёстких требованиях к latency — но не вместо.

Самый недооценённый по бюджету слой — коннекторы и индексация. На бумаге он выглядит технически несложным, на практике в нём оседает заметная часть времени пилота. Форматы документов в реальных СЭД (1С:Документооборот, Directum, Тезис) почти никогда не совпадают с тем, что описано в спецификации интеграции. Нормализация, дедупликация, очистка от ПДн, работа с нестандартными форматами файлов — это не часы, а дни и недели. «Подключим коннектор» в ТЗ обычно превращается в отдельную инженерную задачу.

3.2 Поток данных

Запрос пользователя проходит восемь обязательных этапов. Этот поток одинаков для большинства сценариев — отличается только содержание промпта и состав источников контекста.

Шаг 1 Пользователь	Запрос через web/API с авторизацией заказчика (SSO, AD/LDAP)
Шаг 2 Шлюз доступа	RBAC: контроль прав на источники, маршрутизация по контурам данных
Шаг 3 ИБ-фильтр входа	Маскирование чувствительных полей, проверка категорий доступа, защита от prompt injection
Шаг 4 RAG-оркестратор	Семантический поиск контекста в векторной БД, ранжирование, дедупликация
Шаг 5 LLM-узел	Генерация ответа на GPU-узле в периметре заказчика. Модель без выхода в публичный интернет
Шаг 6 ИБ-фильтр выхода	DLP-проверка исходящего ответа на утечку чувствительных данных
Шаг 7 Журналирование	Полная фиксация запроса, ответа, источников, идентификатора пользователя — отправка в SIEM
Шаг 8 Ответ пользователю	Текст ответа со ссылками на исходные документы, версию контекста
Формат В этом документе схема показана текстом. В реальном проекте поток данных оформляется как HLD-диаграмма с обозначением сетевых сегментов, шлюзов, точек контроля и интеграционных интерфейсов.	

4. ИБ-обязка вокруг модели

Сама LLM не является средством защиты информации. Эту функцию выполняет обязанка из отдельных компонентов. В зрелом промышленном внедрении их обычно шесть-восемь, в пилоте часть может быть в минимальном виде. Ниже эти компоненты сгруппированы по решаемым задачам.

4.1 Идентичность, доступ, аудит

Это самый плотный блок. Доступ к источникам и сценариям выдаётся по ролям и контурам данных: оператор контакт-центра не должен видеть документы юридического или казначейского контура. RBAC реализуется на уровне векторной базы через фильтрацию по метаданным и на уровне шлюза доступа.

Параллельно работает журналирование: кто, когда, по какому документу или кейсу обращался к модели, какой получил ответ. Полная фиксация. Логи отправляются в SIEM заказчика как стандартные ИБ-события, и через корреляцию с другими источниками (VPN, СЭД, DLP) выстраивается общая картина действий пользователя.

4.2 Контроль чувствительных данных

Чувствительные поля — ФИО, номера документов, паспортные данные, банковские реквизиты — проходят через модуль маскирования. Он может стоять только на входе (в промпте), только на выходе (в ответе) или с обеих сторон, в зависимости от модели угроз.

В проектах под КИИ и обработку ПДн обычно ставится двойной контур: маскирование на входе плюс DLP-фильтр на выходе. Маскирование на входе закрывает риск попадания чувствительных полей в оперативную или обучающую память модели, DLP на выходе — риск утечки через случайно попавший в контекст фрагмент. Маскирование только на выходе — это компромисс для сценариев, где живые данные в промпте критичны для качества и нет технической возможности маскировать на входе без потери релевантности.

Правила DLP здесь те же, что в остальной инфраструктуре заказчика: запрет упоминания внутренних кодов проектов, числовых маркеров, имён сотрудников. Если у заказчика DLP уже стоит, имеет смысл интегрироваться с ним, а не строить параллельные правила.

4.3 Изоляция и жизненный цикл модели

LLM-узел не имеет прямого выхода в публичный интернет. Доступ из общего корпоративного сегмента — только через авторизацию и шлюз. Обновления модели и зависимостей идут отдельной процедурой через тестовую среду.

Каждая версия модели — отдельный артефакт с фиксированной контрольной суммой и описанием изменений. Это нужно для отзывной политики: если выяснится, что конкретная версия подвержена какому-то типу атак, должна быть процедура её отката.

4.4 Защита от атак через данные

Главный современный вектор атаки на LLM-систему — это документы в RAG-контексте. Вредоносный фрагмент текста в индексированном документе может инструктировать модель раскрыть содержимое из соседних документов или выйти за рамки сценария.

Защита строится через регулярное тестирование красной командой, фрагменты-приманки в тестовой среде, автоматизированные сценарии атак. Принципиальное требование к red team — независимость от разработки и от команды развёртывания: на момент тестирования у команды не должно быть доступа к внутренней документации системы. Внутренняя это команда или специализированный подрядчик — определяется под проект и обычно обсуждается с заказчиком. Это не разовая настройка, а процесс.

5. Совместимость и стек

Один из первых вопросов технического специалиста заказчика — совместимость с отечественным стеком. Ниже основные категории.

5.1 Операционные системы

ОС	Особенности	Когда применять
Astra Linux Common Edition	Сертифицирована ФСТЭК; работа с КИИ	Большинство значимых объектов КИИ, госсектор
Astra Linux Special Edition	Уровни защищённости (Орёл, Воронеж, Смоленск)	Объекты с повышенными требованиями к защите
РЕД ОС	Сертифицирована ФСТЭК; коммерческая поддержка	Госсектор, корпоративный сегмент
ALT Linux	Свободная и коммерческая редакции	Гибкие сценарии, образовательный сектор
Windows Server	Применимо там, где не противоречит требованиям	Сегменты без формального ограничения на ОС

К версиям

Astra Linux Special Edition с уровнями защищённости (Орёл, Воронеж, Смоленск) — это объекты со значимостью 1 категории по КИИ и системы с высшей степенью конфиденциальности. В большинстве коммерческих и госсекторных проектов хватает Common Edition. Конкретная редакция и уровень защищённости определяются на проектировании совместно со службой защиты информации заказчика — заранее выбирать SE «на всякий случай» обычно избыточно.

5.2 СУБД и векторное хранилище

Из отечественных СУБД в проектах под КИИ и госсектор обычно используется Postgres Pro Certified — сертифицированный PostgreSQL с расширением pgvector для векторного поиска. Это самый частый выбор: проходит формальные фильтры закупок и закрывает базовые векторные сценарии.

Где Postgres Pro упирается в производительность (десятки миллионов векторов, жёсткие требования к latency) — добавляются специализированные векторные базы: Milvus или Qdrant. В чистом виде их обычно ставят в дополнение, а не вместо. Из аналитических СУБД в инфраструктуре встречаются Tantor и Arenadata DB.

5.3 Виртуализация и контейнеризация

- «РусБИТех» Брест — отечественная платформа виртуализации, совместимая с Astra Linux.
- ECP Veil — платформа виртуализации, ориентированная на госсектор и КИИ.
- Kubernetes как стандарт оркестрации: применяются отечественные дистрибутивы (Deckhouse, ALT K8s) либо собственная сборка.

5.4 Аппаратное обеспечение (GPU)

Минимальные требования зависят от размера модели и нагрузки. В таблице ниже — ориентир для сценариев пилота и промышленного запуска.

Сценарий	Размер модели	GPU (минимум)	RAM	Диск NVMe
Пилот, один кейс	7B–13B параметров	1 × A100 80GB или эквивалент	64–128 ГБ	1 ТБ
Промышленный, 2–3 кейса	13B–30B параметров	2 × A100/H100 с резервом	256 ГБ+	2–4 ТБ
Корпоративная платформа	30B–70B + специализированные	Кластер GPU 4+	512 ГБ+	Распределённое хранилище

Чаще встречается недозаказ железа, чем перезаказ. Типовая ошибка самостоятельной оценки заказчика — «нашли в интернете минимальные требования для модели 13B и заказали по ним». Это число — про запуск модели, а не про работу под целевой нагрузкой. Количество одновременных пользователей, длина контекста, latency-требования кратно влияют на итоговую конфигурацию: то, что хватало одному пользователю в демо, перестаёт работать на десяти параллельных запросах в реальном сценарии.

К цифрам

Цифры в таблице — порядки величин, не спецификация T3. SKU GPU корректно подбирать только после замеров целевой нагрузки: rps, latency и длина контекста влияют сильно.

6. Сценарии развёртывания

В практике крупных российских внедрений встречаются три типовых варианта: они отличаются масштабом, бюджетом и составом команды. Между ними нет жёстких границ — скорее это удобные ориентиры для разговора с заказчиком.

6.1 Минимальный сценарий: пилот на один кейс

Исходная точка для большинства проектов. Цель — за минимальный срок и бюджет проверить применимость в одном конкретном бизнес-сценарии и понять, стоит ли идти дальше. Развёртывание идёт в выделенном тестовом сегменте.

Аппаратно достаточно одного GPU-узла и модели на 7–13 миллиардов параметров (open-source или сертифицированный аналог). Один RAG-сценарий, один источник данных, тестовая выборка. Из ИБ-обвязки на этом этапе хватает RBAC и журналирования.

Команда со стороны интегратора в минимальной конфигурации — три роли: архитектор, ML-инженер, специалист по ИБ. При честном счёте к ним добавляются «полставки» DevOps на развёртывание окружения, аналитик данных на работу с сырым корпусом документов и project manager на координацию с заказчиком. Плюс обязательные ответственные со стороны заказчика — отдельно по ИТ и отдельно по ИБ, это два разных человека. Итого «три человека» в плане при честном счёте превращаются в команду 5–7 человек с обеих сторон. Срок: 4–8 недель в зависимости от сложности сценария и готовности данных.

Вариант подходит для первого пилота, проверки качества модели на специализированной терминологии и оценки технической команды интегратора.

6.2 Промышленный сценарий: 2–3 кейса в работе

Шаг к промышленному запуску. Несколько сценариев работают на согласованных данных и интеграциях, развёртывание уходит из тестового сегмента в основной корпоративный, но с изоляцией от публичных сетей.

Аппаратная база растёт до двух GPU-узлов с резервированием, модели — 13–30 миллиардов параметров, под разные сценарии разные. Три-пять RAG-сценариев, множественные источники: СЭД, файловые хранилища, регламентные базы. ИБ-обвязка собирается полностью: маскирование, DLP, SIEM-интеграция, защита от prompt injection. Интеграции со СЭД, СУБД, SIEM и DLP заказчика делаются «по-настоящему», не demo-уровня.

Срок: три-шесть месяцев. Стоимость зависит от количества и сложности интеграций гораздо сильнее, чем от выбора модели.

В нашей практике самый длинный пилот шёл шесть месяцев при изначально запланированных трёх. Это был проект в крупной структуре, и обе причины затягивания оказались на стороне организации заказчика, не технические: согласование доступов к конфиденциальным базам данных и выделение изолированных тестовых аппаратных мощностей в контуре ИБ. Это иллюстрирует

общую закономерность: на собственно технических этапах сроки предсказуемы; теряются они там, где пилот пересекается с внутренними процессами заказчика.

6.3 Корпоративная платформа

Зрелая стадия — ИИ как платформенный сервис нескольких подразделений компании. Развёртывание в выделенном сегменте с собственной службой эксплуатации.

Кластер GPU с горизонтальным масштабированием, модели до 70 миллиардов параметров плюс специализированные (видеоаналитика, аудио, мультимодальные). Десятки и больше сценариев в разных подразделениях. Multi-tenant с изоляцией контуров: юридический, финансовый, операционный, ИБ работают рядом, но не видят данных друг друга. К полной ИБ-обвязке добавляется интеграция с Compliance-аудитом.

Срок развёртывания: 6–12 месяцев, дальше — поддержка и развитие.

7. Методология пилота за 4–8 недель

Пилотный проект — это не «маленькое промышленное внедрение». У него своя структура с фиксированными критериями приёмки, и его смысл — дать заказчику обоснованное решение, переходить к промышленному запуску или нет.

7.1 Структура пилота

Недели 1–2: Обследование

Самая важная и самая недооценённая фаза. Заполняется опросный лист (см. чек-лист в разделе 8), определяется один — максимум два — приоритетных сценария.

Согласуются критерии приёмки: какая точность, какой latency, какое покрытие считаем успехом. Параллельно готовится тестовый периметр и согласуется сетевая схема. Данные для индексации подбираются тестовые, без реальных ПДн на этом этапе.

Два пункта опросного листа, которые заказчик чаще всего не закрывает с ходу: детальные технические параметры интеграционных интерфейсов (API, схемы БД, форматы выгрузок) унаследованных корпоративных систем — СЭД, ERP, SCADA — и формальные, измеримые математические критерии успешности пилота (точность ответов, допустимый процент галлюцинаций). Эти два пробела чаще всего и становятся причиной переработки на финальных неделях.

Категория КИИ — отдельный сюжет. Большинство крупных предприятий знает свой общий статус субъекта КИИ, но точную категорию значимости для конкретной целевой системы, в которую интегрируется ИИ, на первом звонке называют не все. С этим работаем на обследовании совместно со службой ИБ заказчика: определение категории критично для выбора уровня защищённости ОС, СУБД и аттестации компонентов.

Если на обследовании экономят и сразу переходят к развёртыванию, расплата приходит на 5–6 неделе.

Недели 3–4: Развёртывание

LLM-узел встаёт на согласованное железо. Настраивается RAG-pipeline: коннекторы, эмбединги, векторная база. Загружается и индексируется подготовленная тестовая выборка. Минимальная ИБ-обвязка: RBAC и журналирование. К концу четвёртой недели — промежуточная демонстрация заказчику.

Недели 5–6: Тестирование и доводка

Самая сложная фаза пилота. На технических этапах сроки и качество предсказуемы; на 5–6 неделе вскрывается всё, что недоделали на обследовании. Если массив тестовых данных подобрали с компромиссом — оказывается, что индексировали не то, что нужно для целевого сценария. Если критерии приёмки не были зафиксированы цифрами — обнаруживается, что реальное качество ответов и latency не сходятся с ожиданиями ЛПР.

Содержательно неделя 5–6 идёт по плану: прогон на эталонном наборе запросов, калибровка качества (Recall@k, Precision, ручная экспертная проверка), замер времени

отклика под целевой нагрузкой, тесты безопасности — попытки prompt injection, проверка журналирования, тесты RBAC. По обратной связи идёт доводка.

Из метрик ЛПР продаётся не Recall@k, а ручная экспертная проверка: 20–30 реальных запросов из бизнес-практики с показом, что система даёт релевантный ответ со ссылкой на источник. Это работает на уровне «понимает наш язык и находит нужное в наших документах». Recall@5 = 0.87 — это число для архитектора, в защите перед руководителем оно почти не работает: человек, не открывавший статью по Information Retrieval, не возьмётся принимать решение на этом основании.

Недели 7–8: Сдача

Финальная демонстрация, sanity-метрики, отчёт по результатам, план промышленного развёртывания со сроками, бюджетом и составом команды. Решение о следующем этапе принимается на основании измеренных данных, а не презентации.

7.2 Что в пилотном пакете и что вне его

В пилотный пакет входят архитектурный документ (HLD) развёрнутого решения, отчёт по результатам тестирования с метриками, чек-лист готовности к промышленному запуску, план доработки с оценкой бюджета и презентация для внутреннего комитета заказчика.

За рамками пилота остаются интеграция со всеми системами заказчика, миграция реальных производственных данных (только тестовая выборка), сертификация средств защиты, обучение операторов в полном объёме. Это задачи следующих этапов.

8. Чек-лист готовности к пилоту

Если этот чек-лист заполнен до встречи с интегратором, пилот стартует на 2–3 недели быстрее: пресейл закрывает половину вопросов сразу. Если на половину пунктов пока нет ответа — это нормально, остальное проработаем на обследовании.

Сценарий и регуляторика

- Определён сценарий пилота (RAG-поиск, контентный анализ, помощник оператора или что-то ещё).
- Известен ориентировочный объём данных: количество документов, ГБ, типы файлов.
- Подготовлен тестовый набор данных без реальных ПДн.
- Согласованы критерии приёмки — что считаем успешным результатом.
- Определена категория объекта по КИИ (1, 2, 3 или объект не относится к КИИ).
- Согласована необходимость аттестации компонентов решения.
- Определены отраслевые регуляторные требования (ЦБ, Ростехнадзор, Роскомнадзор и т.п.).

Инфраструктура

- Известны требования к ОС (Astra Linux, РЕД ОС или иная).
- Известна целевая СУБД (Postgres Pro или иная).
- Доступна GPU-инфраструктура или принято решение арендовать на время пилота.
- Согласован периметр пилота: выделенный тестовый или основной корпоративный.
- Согласован формат журналирования и интеграция с SIEM.

Организация

- Определены ответственные со стороны заказчика по ИТ и по ИБ — это два разных человека.
- Согласован бюджет пилота и формат расчёта.
- Согласован срок (4, 6 или 8 недель).
- Согласован формат финальной презентации: комитет, рабочая группа, демонстрация.

9. Реестр рисков

Это не окончательный перечень рисков. Полный реестр всегда строится под конкретный объект и часто наполовину состоит из специфических для отрасли рисков, которых здесь нет. Но эти шесть встречаются почти в каждом проекте.

Риск	Вероятность	Воздействие	Митигация
Низкое качество модели на специализированной терминологии заказчика	Высокая	Среднее	Тщательно отбираем модель для эмбедингов, при необходимости делаем fine-tuning или domain adaptation. Чаще всего хватает первого.
Утечка чувствительных данных через ответы модели	Низкая	Высокое	DLP-фильтр на исходящих ответах, журналирование всех ответов, выборочный аудит.
Prompt injection через документы в RAG-контексте	Средняя	Среднее	Регулярное тестирование, изоляция пользовательского контекста, проверка источников до индексации.
Изменение регуляtorики в горизонте проекта	Низкая	Высокое	Закладываем архитектуру с возможностью замены модели и компонентов, по возможности используем сертифицированные сборки.
Длительный цикл согласования внутри заказчика	Высокая	Низкое	Запускаем пилот в выделенном тестовом периметре до основных согласований. Параллельно идёт подготовка документов для постоянного контура. На сроки промышленного запуска чаще всего влияют не технические факторы, а параллельные проекты внутри заказчика, конкурирующие за сетевые сегменты, серверную ёмкость и время ИБ-специалистов.
Зависимость от одного интегратора (vendor lock-in)	Средняя	Среднее	Архитектура на открытых компонентах, документация HLD/LLD, передача исходного кода заказчику. Никакого «секретного соуса».

10. О компании AZONE-AI

AZONE-AI — направление искусственного интеллекта компании ООО «Азон», системного интегратора с опытом работы на ИТ-рынке с 2003 года. Лицензии ФСТЭК, ФСБ и МО РФ позволяют работать с объектами критической информационной инфраструктуры, государственной тайной и в защищённых периметрах.

10.1 Продуктовая линейка

- **AzoneDoc** — управление документами с семантическим поиском в закрытом контуре. Интеграция с СЭД, ERP, файловыми хранилищами.
- **ContentGuard** — on-premise ИИ-аналитика событий информационной безопасности. Интеграция NGFW, DLP, EDR, SIEM через единый аналитический слой.
- **ConstructionEye** — видеоаналитика безопасности на промышленных и строительных объектах: контроль СИЗ, периметра, нарушений.
- **PredictMaintain** — предиктивная аналитика промышленного оборудования. Интеграция со SCADA и телеметрией.
- **ContractGuard** — ИИ-ассистент для договорной работы. Анализ, сравнение версий, выявление рисков формулировок.

10.2 Сервисы

- Внедрение LLM on-premise в закрытом контуре.
- Пилотный проект ИИ за 4–8 недель.
- Внедрение RAG-системы для корпоративных знаний.
- ИИ для объектов критической информационной инфраструктуры.

10.3 Как начать

Свяжитесь с нами через сайт azoneai.ru или по контактам ниже. Мы проведём обследование по чек-листу из раздела 8, подготовим архитектурный документ и оценку стоимости пилота.

Контакты

Сайт: azoneai.ru

Email: order@azone-it.ru

Телефон: +7 (495) 902-66-36

Офис: Москва, ул. Прянишникова, д. 23А

ООО «Азон» · ИНН/КПП согласно реквизитам · лицензии ФСТЭК, ФСБ, МО РФ — номера на сайте.

Условия использования

Документ предоставлен для ознакомления специалистам заказчика. Содержит общие архитектурные рекомендации и не заменяет проектной документации, разрабатываемой для конкретного объекта. Цифры (бюджет, сроки, GPU SKU, версии ОС) — ориентир, точные значения определяются на обследовании.